PROTOCOLO DE INVESTIGACIÓN

DOCTORADO EN CIENCIAS ECONÓMICAS EMPRESARIALES

PRESENTA: GERMÁN PATRICIO BARRA ÁVILA

ASESOR: DR. ALEJANDRO HÉCTOR MOLINA

Modelación del desempeño económico del clúster turístico de la Región de La Araucanía mediante técnicas de Machine Learning aplicadas a datos públicos para la toma de decisiones territoriales.

CHILE, SANTIAGO MARZO, 2026

ÍNDICE

1 INTRODUCCIÓN 3
2 DEFINICIÓN DEL PROBLEMA DE INVESTIGACIÓN 4
3 JUSTIFICACIÓN 5
3.1 Justificación académica 5
3.2 Justificación social y territorial 5
3.3 Justificación metodológica 5
3.4 Viabilidad del proyecto 5
4 OBJETIVOS 6
4.1 Metas del estudio 6
4.2 Objetivo general 6
4.3 Objetivos específicos 6
5 HIPÓTESIS O SUPUESTO DE INVESTIGACIÓN 7
5.1 Hipótesis general: 7
5.2 Hipótesis específicas: 7
6 METODOLOGÍA 9
6.1 Paradigma y enfoque 9
6.2 Tipo de investigación 9
6.3 Población y muestra 9
6.4 Fuentes de datos 9
6.5 Variables Dependientes e Independientes 10
6.6 Unidad de análisis 10
6.7 Técnicas de análisis 11
6.8 Validación y Robustez 15
6.9 Procedimiento y Cronograma 16
6.10 Consideraciones éticas 16
7 REFERENCIAS 17

1 INTRODUCCIÓN

El turismo constituye uno de los sectores estratégicos para el desarrollo económico regional, especialmente en territorios con alta dotación de recursos naturales y culturales, como la Región de La Araucanía en Chile. En este contexto, la conformación de clústeres turísticos permite articular actores públicos y privados, generar economías de aglomeración y potenciar el desempeño económico territorial. No obstante, la creciente disponibilidad de datos públicos asociados al sector turístico contrasta con un uso aún limitado de metodologías analíticas avanzadas que permitan aprovechar dicha información de manera sistemática y predictiva.

En los últimos años, las técnicas de Machine Learning han adquirido relevancia en el análisis económico y territorial, al permitir identificar patrones complejos, relaciones no lineales y comportamientos emergentes a partir de grandes volúmenes de datos. Estas herramientas han sido utilizadas con éxito en ámbitos como la predicción de demanda, la segmentación de mercados y el análisis de desempeño económico, aunque su aplicación al estudio de clústeres turísticos regionales, especialmente en contextos latinoamericanos y con datos públicos, sigue siendo incipiente.

En este estudio, el desempeño económico del clúster turístico se entenderá como una construcción analítica basada en la combinación de indicadores de actividad turística, empleo, ingresos y dinamismo territorial, obtenidos a partir de fuentes públicas oficiales. Esta definición permite operacionalizar el concepto de desempeño económico de manera objetiva y replicable, facilitando su modelación mediante técnicas cuantitativas avanzadas.

La presente investigación se propone contribuir a la literatura económica y territorial mediante la aplicación de técnicas de Machine Learning a datos públicos para modelar el desempeño económico del clúster turístico de la Región de La Araucanía, generando evidencia empírica que apoye la toma de decisiones territoriales basadas en datos. El estudio se estructura en torno a la definición del problema de investigación, la revisión del marco teórico, la formulación de objetivos e hipótesis, el diseño metodológico y la presentación de un plan de trabajo acorde con los plazos del programa doctoral.

2 DEFINICIÓN DEL PROBLEMA DE INVESTIGACIÓN

A pesar de la relevancia económica y social del turismo en la Región de La Araucanía, la evaluación del desempeño económico del clúster turístico regional se ha basado principalmente en análisis descriptivos y enfoques tradicionales, que no siempre logran capturar la complejidad de las interacciones entre variables económicas, territoriales y productivas. Paralelamente, existe una creciente disponibilidad de datos públicos provenientes de organismos como el Instituto Nacional de Estadísticas, el Servicio Nacional de Turismo y el Ministerio de Economía, los cuales permanecen subutilizados desde una perspectiva analítica avanzada.

El problema central de esta investigación radica en la ausencia de modelos integrados que permitan analizar y modelar el desempeño económico del clúster turístico regional utilizando técnicas de Machine Learning aplicadas a datos públicos. Esta brecha metodológica limita la capacidad de generar información predictiva y explicativa que apoye la formulación de políticas públicas y decisiones estratégicas territoriales basadas en evidencia.

Para efectos de esta investigación, el desempeño económico del clúster turístico se conceptualiza como un indicador compuesto, denominado Índice de Desempeño Económico del Clúster (IDEC), construido a partir de variables observables de actividad turística, empleo sectorial, generación de ingresos y capacidad productiva, obtenidas de fuentes públicas oficiales. Esta operacionalización permite contar con una variable dependiente única, necesaria para la aplicación coherente de técnicas de aprendizaje supervisado y la evaluación de su capacidad predictiva.

A partir de lo anterior, surge la siguiente pregunta de investigación:

¿En qué medida la aplicación de técnicas de Machine Learning a datos públicos permite modelar con mayor precisión predictiva que enfoques tradicionales el desempeño económico del clúster turístico de la Región de La Araucanía para apoyar la toma de decisiones territoriales?

3 JUSTIFICACIÓN

3.1 Justificación académica

La investigación contribuye al campo de las ciencias económico-empresariales al integrar enfoques de economía regional, análisis de clústeres y técnicas de Machine Learning, fortaleciendo la literatura empírica sobre aplicaciones avanzadas de analítica de datos en estudios territoriales, lo que resulta pertinente con los lineamientos del Doctorado en Ciencias Económicas Empresariales, particularmente en el análisis del desempeño económico territorial y la aplicación de métodos cuantitativos avanzados.

3.2 Justificación social y territorial

Los resultados permitirán mejorar la comprensión del funcionamiento económico del turismo regional, aportando evidencia para el diseño de políticas públicas orientadas al desarrollo sostenible, la competitividad y la cohesión territorial en la Región de La Araucanía.

3.3 Justificación metodológica

El uso de datos públicos abiertos garantiza replicabilidad, transparencia y viabilidad, alineándose con estándares contemporáneos de investigación científica y gobierno abierto.

3.4 Viabilidad del proyecto

El estudio es viable dado el acceso a fuentes públicas oficiales (INE, SERNATUR, Banco Central, datos abiertos gubernamentales) y la disponibilidad de herramientas computacionales de código abierto para la implementación de técnicas de Machine Learning.

4 OBJETIVOS

4.1 Metas del estudio

¿Qué se espera lograr? Se busca desarrollar un modelo analítico para transformar datos públicos en evidencia cuantitativa para la toma de decisiones territoriales. El resultado esperado es un modelo capaz de predecir tendencias económicas y clasificar el desempeño del clúster, permitiendo a los tomadores de decisiones anticiparse a crisis de estacionalidad y optimizar la inversión pública.

4.2 Objetivo general

Modelar y evaluar comparativamente el desempeño económico del clúster turístico de la Región de La Araucanía mediante técnicas de Machine Learning aplicadas a datos públicos, con el fin de apoyar la toma de decisiones territoriales.

4.3 Objetivos específicos

1. Identificar las variables económicas y territoriales relevantes del clúster turístico de la Región de La Araucanía a partir de fuentes de datos públicos.

2. Aplicar técnicas de Machine Learning para estimar y predecir el desempeño económico del clúster turístico.

3. Analizar los patrones y relaciones identificados por los modelos en el comportamiento del clúster turístico.

4. Determinar el aporte de los modelos desarrollados para la toma de decisiones territoriales basadas en evidencia.

5 HIPÓTESIS O SUPUESTO DE INVESTIGACIÓN

5.1 Hipótesis general:

La aplicación de técnicas de Machine Learning a datos públicos permite modelar de manera significativa (estadística y predictivamente), con mayor precisión predictiva que modelos econométricos tradicionales el desempeño económico del clúster turístico de la Región de La Araucanía, generando evidencia empírica relevante para la toma de decisiones territoriales.

5.2 Hipótesis específicas:

H1: Las variables económicas y territoriales obtenidas de fuentes públicas presentan una relación estadísticamente significativa, potencialmente no lineal, con el Índice de Desempeño Económico del Clúster (IDEC).

Indicadores asociados

- Llegadas y pernoctaciones turísticas
- Empleo en actividades de alojamiento y servicios turísticos
- Ingresos turísticos estimados (Cuenta Satélite de Turismo)
- Capacidad y ocupación de alojamiento

H2: Los modelos de aprendizaje supervisado permiten estimar el IDEC con niveles de error predictivo aceptables, medidos mediante indicadores como el error absoluto medio (MAE), el error cuadrático medio (RMSE) y el coeficiente de determinación (R^2).

Indicadores asociados

- RMSE
- MAE
- R^2

H3: Las técnicas de aprendizaje no supervisado permiten identificar patrones y agrupamientos territoriales diferenciados dentro del clúster turístico de la Región de La Araucanía, evaluados mediante indicadores de cohesión y separación como el coeficiente de silueta.

Indicadores asociados

- Número de clústeres identificados
- Coeficiente de silueta
- Homogeneidad intra-clúster y heterogeneidad inter-clúster

6 METODOLOGÍA

6.1 Paradigma y enfoque

La investigación se enmarca en el paradigma positivista, con un enfoque cuantitativo, orientado al análisis empírico y la modelación predictiva.

6.2 Tipo de investigación

Estudio aplicado, no experimental, de alcance explicativo y predictivo, basado en análisis secundario de datos públicos.

6.3 Población y muestra

La población corresponde al conjunto de comunas que integran el clúster turístico de la Región de La Araucanía. La muestra se construirá a partir de aquellas comunas para las cuales exista información pública disponible consistente en el período de estudio.

6.4 Fuentes de datos

6.4.1 Instituto Nacional de Estadísticas (INE)

- Encuesta Mensual de Alojamiento Turístico (EMAT).

6.4.2 Servicio Nacional de Turismo (SERNATUR)

- Llegada de turistas (nacionales e internacionales)
- Tasa de ocupabilidad regional,
- Cantidad de prestadores de servicios turísticos registrados.

6.4.3 Banco Central de Chile/Hacienda

- Cifras de inversión pública regional, PIB regional y gasto promedio por turista.

6.4.4 Portales de Datos Abiertos

- Infraestructura vial (conectividad)
- Datos meteorológicos (estacionalidad)
- Eventos culturales registrados.

6.5 Variables Dependientes e Independientes

6.5.1 Variable dependiente:

Índice de Desempeño Económico del Clúster (IDEC), construido como indicador compuesto sintético que integra dimensiones de actividad turística, empleo sectorial, generación de ingresos y capacidad productiva.

6.5.2 Variables independientes (ejemplo):

- Oferta turística
- Demanda turística
- Empleo turístico
- Inversión pública
- Factores territoriales (conectividad, estacionalidad, infraestructura)

6.6 Unidad de análisis

La unidad de análisis corresponderá a la comuna como unidad territorial básica dentro del clúster turístico de la Región de La Araucanía. El estudio se estructurará en formato de datos panel, considerando series temporales agregadas a nivel comunal según disponibilidad de fuentes públicas oficiales

6.7 Técnicas de análisis

La estrategia metodológica se estructura en tres fases analíticas complementarias.

6.7.1 **Fase 1: Construcción del indicador de desempeño económico**

El Índice de Desempeño Económico del Clúster (IDEC) se construirá como un indicador compuesto sintético que integra cuatro dimensiones:

1. Actividad turística
2. Empleo sectorial
3. Generación de ingresos
4. Capacidad productiva

Sea:

$$x_{kjit}$$

el valor observado del indicador $j$de la dimensión k, en la comuna i, en el período t.

Normalización:

Cada variable será normalizada mediante el método Min-Max:

$$Z_{kjit} = \frac{X_{kjit} - \min(X_{kj})}{\max(X_{kj}) - \min(X_{kj})}$$

Donde:

- Zkjit corresponde al valor normalizado en el rango [0,1].
- Los valores mínimo y máximo se calcularán considerando el período completo de análisis, asegurando comparabilidad Inter temporal.

En el caso de indicadores con relación inversa al desempeño económico, se aplicará una transformación previa para mantener consistencia en la dirección interpretativa del índice.

Agregación por dimensión

Cada dimensión se calculará como el promedio simple de sus indicadores normalizados:

$$D_{kit} = \left(\frac{1}{m_k}\right)\sum_{j=1}^{m_k} Z_{kjit}$$

donde:

- $m_k$corresponde al número de indicadores de la dimensión k.

Construcción del IDEC

$$IDEC_{it} = \left(\frac{1}{4}\right)(D_{1it} + D_{2it} + D_{3it} + D_{4it})$$

La utilización de ponderaciones iguales responde a criterios de:

- Transparencia metodológica
- Replicabilidad
- Reducción de arbitrariedad

No obstante, se realizará un análisis de sensibilidad comparando:

- Métodos alternativos de normalización (Min-Max vs Z-score)
- Esquemas alternativos de ponderación

El IDEC constituye la variable dependiente única para efectos de modelación supervisada.

6.7.2 **Fase 2: Modelación predictiva mediante aprendizaje supervisado**

El IDEC será modelado como variable dependiente en un esquema de datos panel mediante técnicas de aprendizaje supervisado, tales como:

- Regresión lineal múltiple (modelo base comparativo)
- Árboles de decisión
- Random Forest

Estas técnicas permiten capturar:

- Relaciones lineales
- Interacciones complejas
- Relaciones potencialmente no lineales

Evaluación predictiva

La evaluación del desempeño predictivo se realizará mediante:

- Error Absoluto Medio (MAE)
- Error Cuadrático Medio (RMSE)
- Coeficiente de Determinación (R^2)

Se aplicará:

- Validación cruzada K-fold
- Partición entrenamiento/prueba

Estas métricas se aplicarán exclusivamente a modelos supervisados, dado que miden capacidad predictiva sobre una variable dependiente cuantitativa.

6.7.3 **Fase 3: Análisis de agrupamiento y desigualdad territorial**

De manera complementaria, se aplicarán técnicas de aprendizaje no supervisado con el objetivo de identificar patrones estructurales y configuraciones territoriales diferenciadas dentro del clúster turístico.

Se utilizarán algoritmos como:

- K-means
- Clustering jerárquico (según pertinencia exploratoria)

Evaluación del agrupamiento

La calidad del clustering será evaluada mediante:

- Coeficiente de silueta
- Índice de Davies-Bouldin (si se requiere contraste adicional)
- Análisis de cohesión intra-clúster
- Separación inter-clúster

Estas métricas permiten evaluar consistencia estructural sin involucrar capacidad predictiva.

Análisis de desigualdad territorial

Adicionalmente, se incorporará el Índice de Theil aplicado al IDEC:

$$T = \frac{1}{N} \sum_{i=1}^{N} \left(\frac{IDEC_{it}}{I\bar{D}EC_t} \ln \frac{IDEC_{it}}{I\bar{D}EC_t} \right)$$

donde:

- $IDEC_{it}$corresponde al desempeño de la comuna i
- $I\bar{D}EC_t$es el promedio regional en el período t
- Nnúmero de comunas

El índice de Theil permite:

- Medir dispersión territorial
- Analizar desigualdad intra e interregional
- Aprovechar propiedades de descomposición territorial

  Este análisis complementa la modelación predictiva con una perspectiva estructural del desempeño económico.

6.8 Validación y Robustez

La validación del modelo se abordará desde tres dimensiones complementarias:

6.8.1 Validación predictiva:

Los modelos supervisados serán evaluados mediante MAE, RMSE y R^2, junto con validación cruzada y partición entrenamiento/prueba.

6.8.2 Validación estructural:

En el caso del análisis de agrupamiento, la calidad de los clústeres será evaluada mediante el coeficiente de silueta y métricas de cohesión y separación.

6.8.3 Robustez del índice compuesto:

Se realizará un análisis de sensibilidad del IDEC evaluando su estabilidad ante variaciones en:

- Esquemas de ponderación
- Métodos de normalización
- Periodos temporales considerados

Este enfoque permite asegurar la consistencia interna del índice y la estabilidad de los resultados obtenidos.

6.9 Procedimiento y Cronograma

El estudio se desarrollará en periodos trimestrales con plazo de entrega el 10DIC2026, conforme al siguiente cronograma.

PERIODO	CAPÍTULO	DESCRIPCIÓN
I Trimestre	Protocolo de Investigación	1. Formulación del protocolo o anteproyecto de investigación.
II Trimestre	Capítulo I: El problema	2. Contexto, justificación y fundamentos que respaldan la investigación, objetivos, hipótesis o supuesto de investigación.
	Capítulo II: El marco teórico	3. Revisión exhaustiva de la literatura relacionada con el tema de investigación. Identificación de teorías, conceptos y modelos relevantes.
	Capítulo III: Marco conceptual e Hipótesis	4. Definición de variables dependiente e independientes. Dimensiones e indicadores. Modelo conceptual de la investigación.
III Trimestre	Capítulo IV: Metodología	5. Diseño detallado de la metodología de investigación (Paradigma, método, fases de la investigación). Selección de herramientas y técnicas de recopilación de datos.
	Capítulo V: Análisis de resultados	6. Implementación de la metodología y recopilación de datos. Inicio del análisis de los resultados obtenidos, con base a los objetivos de investigación.
IV Trimestre	Capítulo VI: Conclusiones	7. Desarrollo de las conclusiones basadas en los hallazgos de la investigación. Refuta o confirma la hipótesis o supuesto de investigación. Reflexión sobre la contribución del estudio al campo de investigación.

6.10 Consideraciones éticas

El estudio utiliza exclusivamente con datos públicos, sin información personal sensible, cumpliendo principios éticos de investigación científica.

7 REFERENCIAS

Aghion, P., Jones, B. F., & Jones, C. I. (2019). Artificial intelligence and economic growth. Journal of Economic Perspectives, 33(2), 163–190. https://doi.org/10.1257/jep.33.2.163

Banco Mundial. (2021). World Development Report 2021: Data for Better Lives. World Bank. https://doi.org/10.1596/978-1-4648-1600-0

Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.

Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324

CEPAL. (2019). Desarrollo territorial en América Latina y el Caribe. Naciones Unidas.

Dolnicar, S., Grün, B., & Leisch, F. (2018). Market Segmentation Analysis: Understanding It, Doing It, and Making It Useful. Springer.

Fagerberg, J., & Srholec, M. (2008). National innovation systems, capabilities and economic development. Research Policy, 37(9), 1417–1435. https://doi.org/10.1016/j.respol.2008.06.003

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction (2nd ed.). Springer.

Instituto Nacional de Estadísticas. (2023). Estadísticas regionales (Base de datos). INE.

Li, X., Pan, B., Law, R., & Huang, X. (2017). Forecasting tourism demand with composite search index. Tourism Management, 59, 57–66. https://doi.org/10.1016/j.tourman.2016.07.005

López, M., & Palomino, H. (2020). Clústeres productivos y desarrollo regional: evidencia para Chile. Revista CEPAL, 131, 87–106.

Ministerio de Economía, Fomento y Turismo. (2022). Cuenta Satélite de Turismo de Chile. Gobierno de Chile.

OECD. (2018). OECD Regions and Cities at a Glance 2018. OECD Publishing. https://doi.org/10.1787/reg_cit_glance-2018-en

OECD. (2020). Machine Learning and Artificial Intelligence in Public Policy. OECD Publishing.

Porter, M. E. (1998). Clusters and the new economics of competition. Harvard Business Review, 76(6), 77–90.

Russell, S. J., & Norvig, P. (2021). Artificial Intelligence: A Modern Approach (4th ed.). Pearson.

Varian, H. R. (2019). Artificial intelligence, economics, and industrial organization. En A. Agrawal, J. Gans, & A. Goldfarb (Eds.), The Economics of Artificial Intelligence: An Agenda (pp. 399–419). University of Chicago Press.